

Estudo Comparativo de Métodos de Inteligência Artificial para Modelagem e Previsão de Rugosidade em Peças Usinadas



Erick Fastera da Silva, Wallace Gusmão Ferreira

Centro de Engenharia, Modelagem e Ciências Sociais Aplicadas, Universidade Federal do ABC
Av. Dos Estados, 5001 – Bangú, Santo André – SP, 09210-580
{eerick@aluno.ufabc.edu.br, wallace.ferreira@ufabc.edu.br}

Resumo: Com o intuito de prever a rugosidade superficial de materiais após usinagem, obtemos um modelo de redes neurais Perceptron Multicamadas, o qual obteve melhores resultados comparados com diversos métodos de predição.

INTRODUÇÃO

A predição das condições finais dos materiais após usinagem de fresamento (Figura 1) é de extrema importância, por conta de sua experimentação ser usualmente lenta, cara e baseada em tentativa e erro.




FIGURA 1: Fresamento com ponta esférica. WANG et al. (2017)

Assim, um modelo de redes neurais, tal como o Perceptron Multicamadas (MLP), é utilizado para a predição da rugosidade superficial média do alumínio após usinagem (Figura 2).

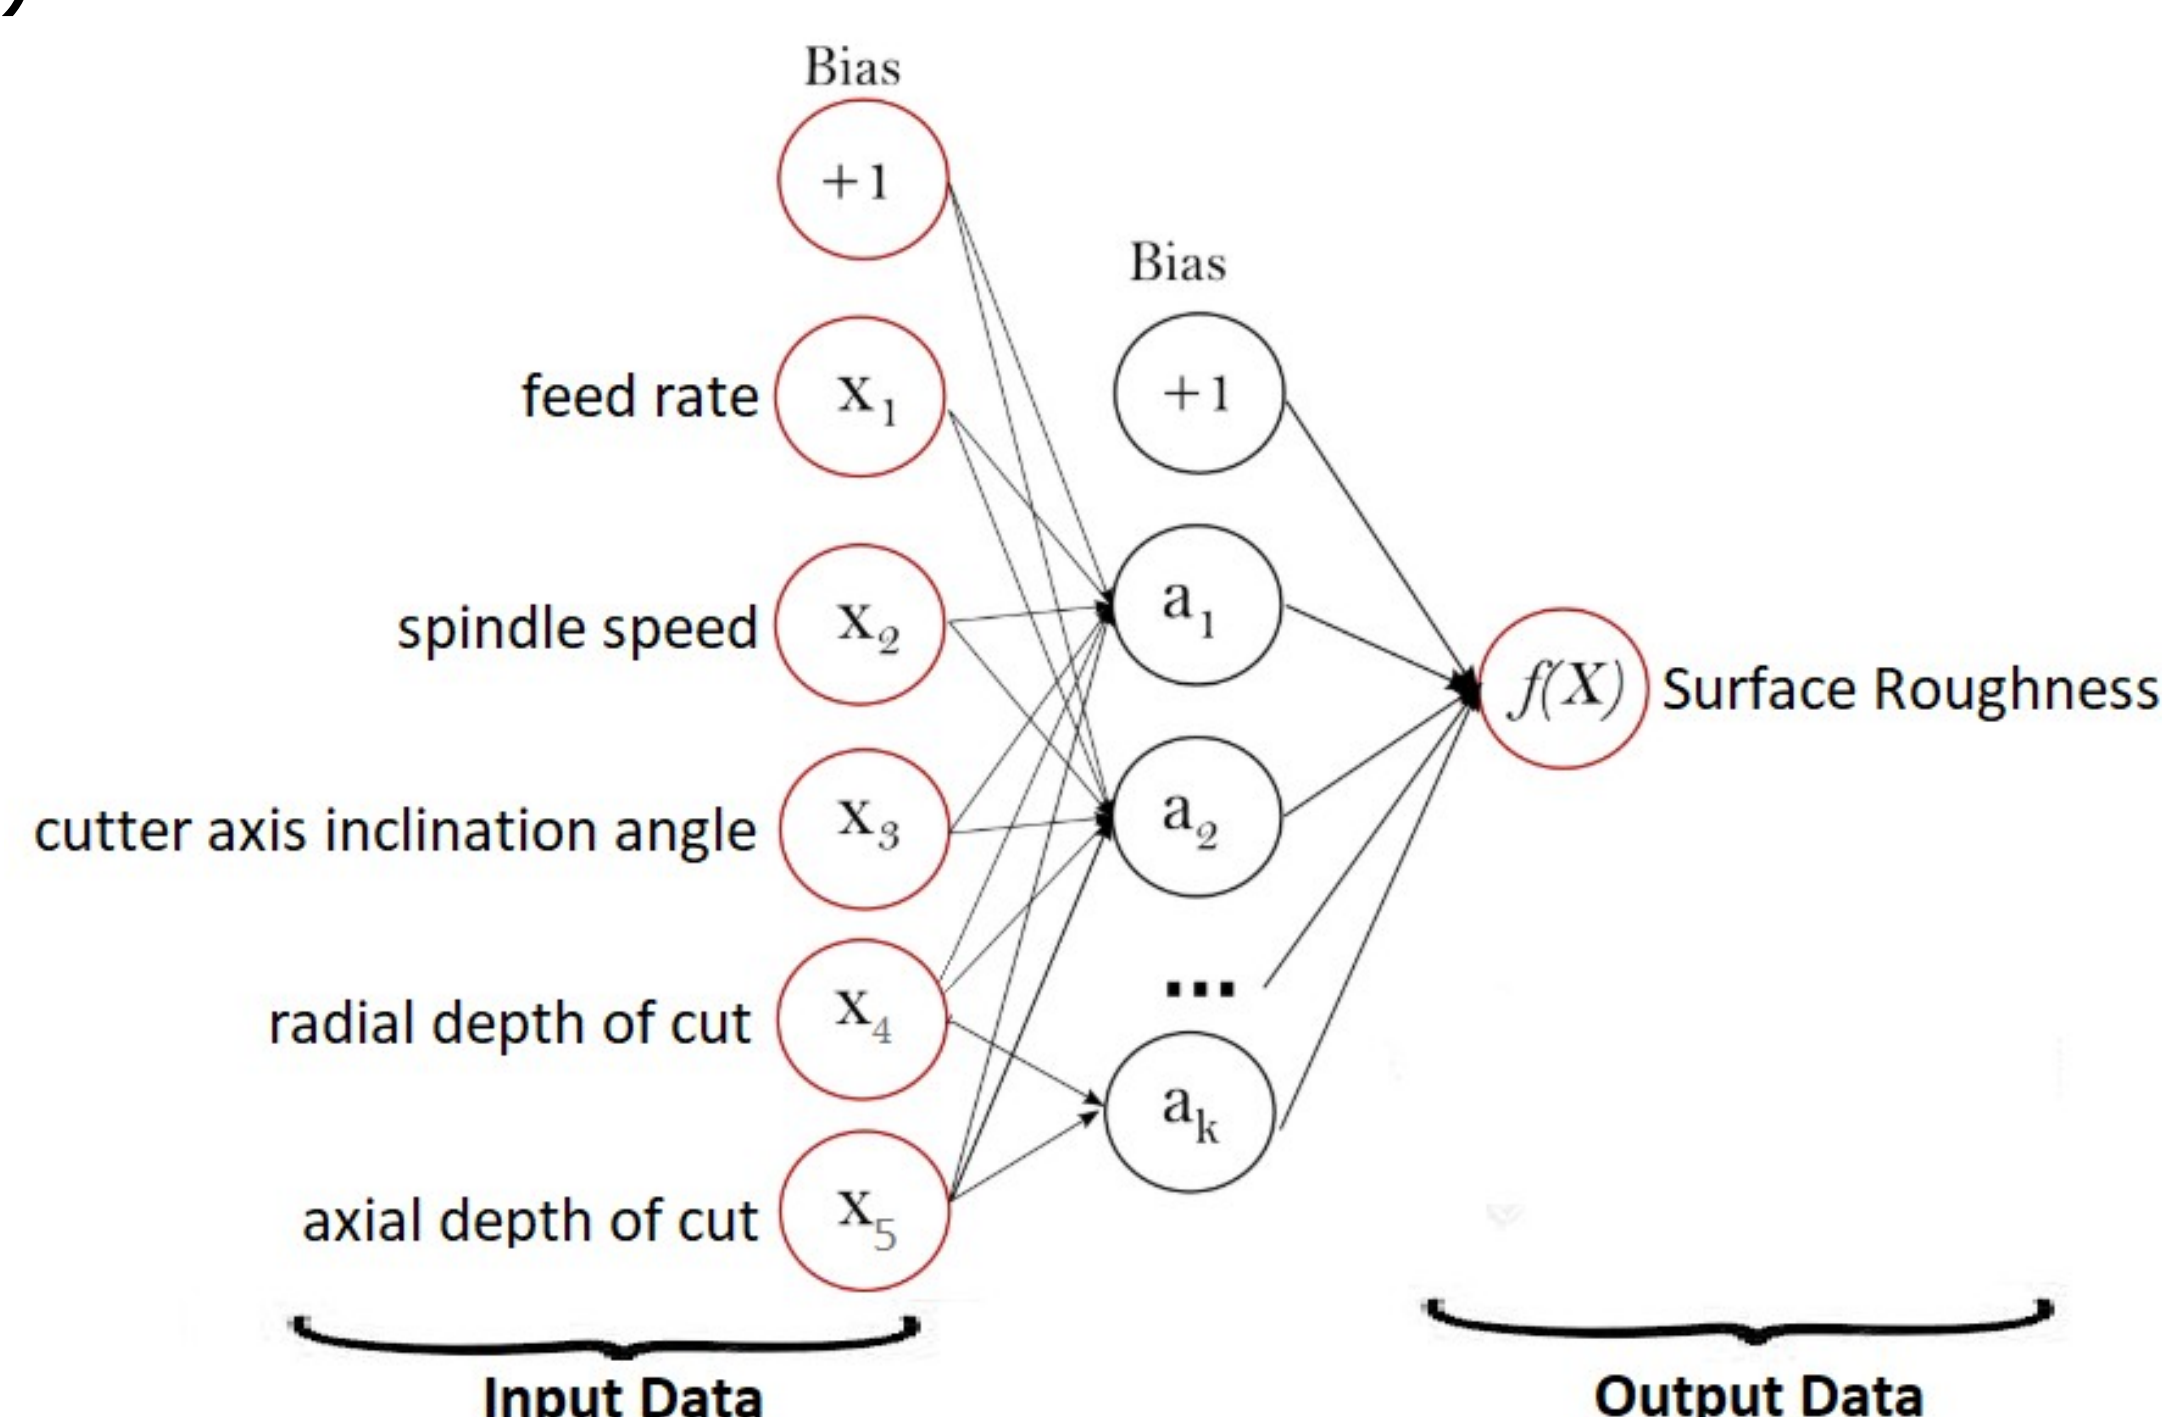


FIGURA 2: Rede Neural Perceptron Multicamadas (MLP).

MATERIAIS E MÉTODOS

Com a linguagem Python e a biblioteca *scikit-learn*, foram utilizados 68 dados de treinamento e 16 dados de teste de HOSSAIN (2012) para calibrar a rede neural MLP. A otimização do sistema foi obtida verificando por busca exaustiva (*grid search*) 336.960 diferentes modelos, variando os hiperparâmetros da Tabela 1.

Para a escolha, foram consideradas as métricas RMSE (Root Mean Square Error), MAPE (Mean Absolute Percentage Error) e R^2 (Coefficient of Determination).

Hiper-parâmetros	Solver	Optimizer	Hidden Layers	Hidden Neurons	Alpha	Batch Size
Variáveis	relu, tanh	adam, lbfgs	1 - 4 camadas	1 - 36 neurônios	$1 \cdot 10^{-2}$, $1 \cdot 10^{-3}$, $1 \cdot 10^{-4}$	2 - 8

Tabela 1: Configurações dos hiperparâmetros utilizados na busca.

RESULTADOS E DISCUSSÕES

As melhores configurações de rede obtidas após a busca exaustiva estão apresentadas na Tabela 2 e nas Figuras 3 e 4, com a comparação dos melhores resultados de HOSSAIN (2012). Os hiperparâmetros otimizados foram: solver "relu", optimizer = "lbfgs", Batch size = 2, e Alpha = 0,01.

Modelos	Treino			Teste		
	RMSE	MAPE	R^2	RMSE	MAPE	R^2
Eq. Teóricas	0.9343	42.0231	0.6432	1.3640	43.8840	0.3750
ANFIS	0.0001	0.0030	0.9999	1.1460	38.6050	0.4626
RSM	0.6306	27.7220	0.8085	0.9000	29.6120	0.6282
ANN	0.0007	0.0314	0.9999	0.9158	34.5351	0.6262
MLP (5-24-1)	0.3505	12.9345	0.9474	0.7353	49.4375	0.6158
MLP (5-7-1)	0.5161	19.0166	0.8717	0.5757	31.5747	0.8352

TABELA 2: Comparação estatística dos modelos de previsão.

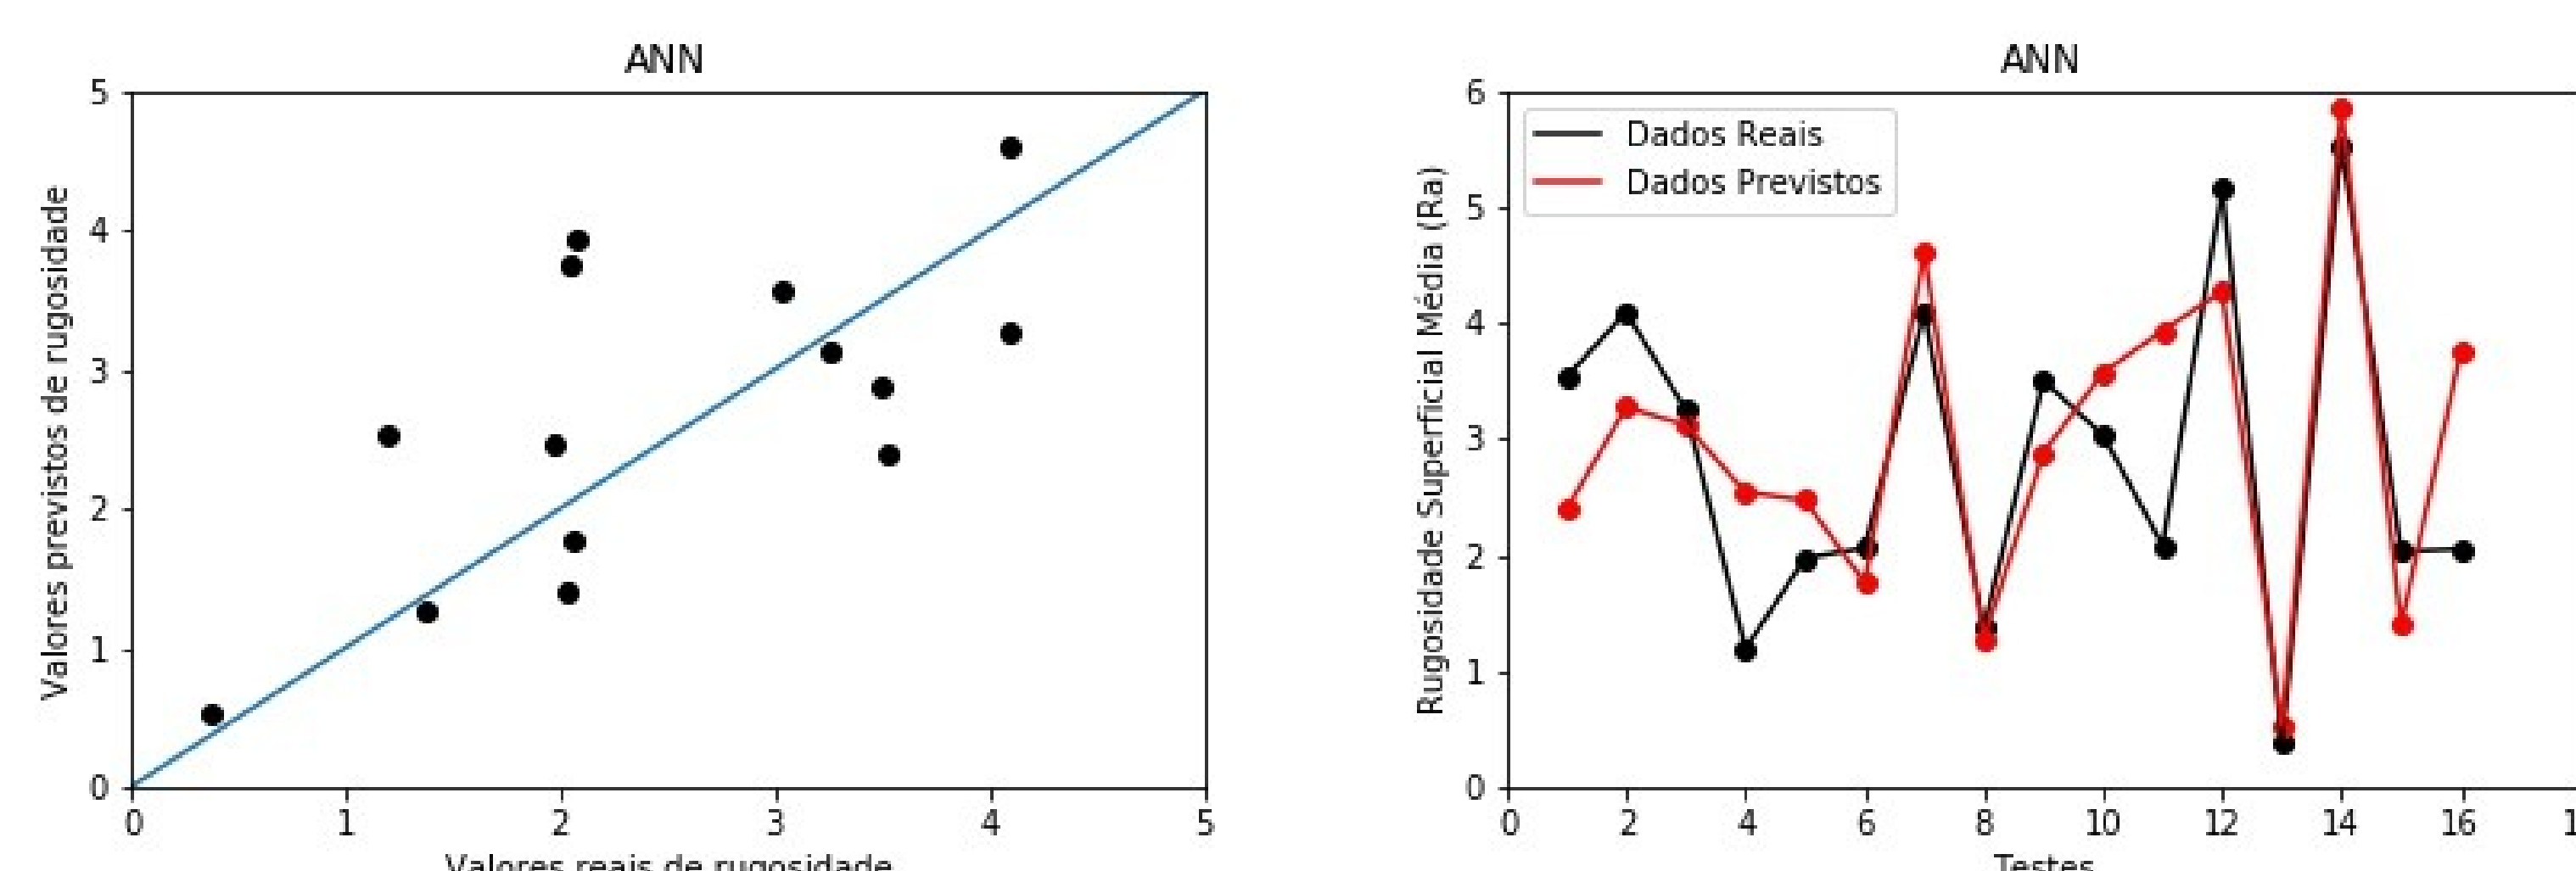


FIGURA 3: Valores reais e previstos de rugosidade utilizando o modelo ANN de HOSSAIN (2012).

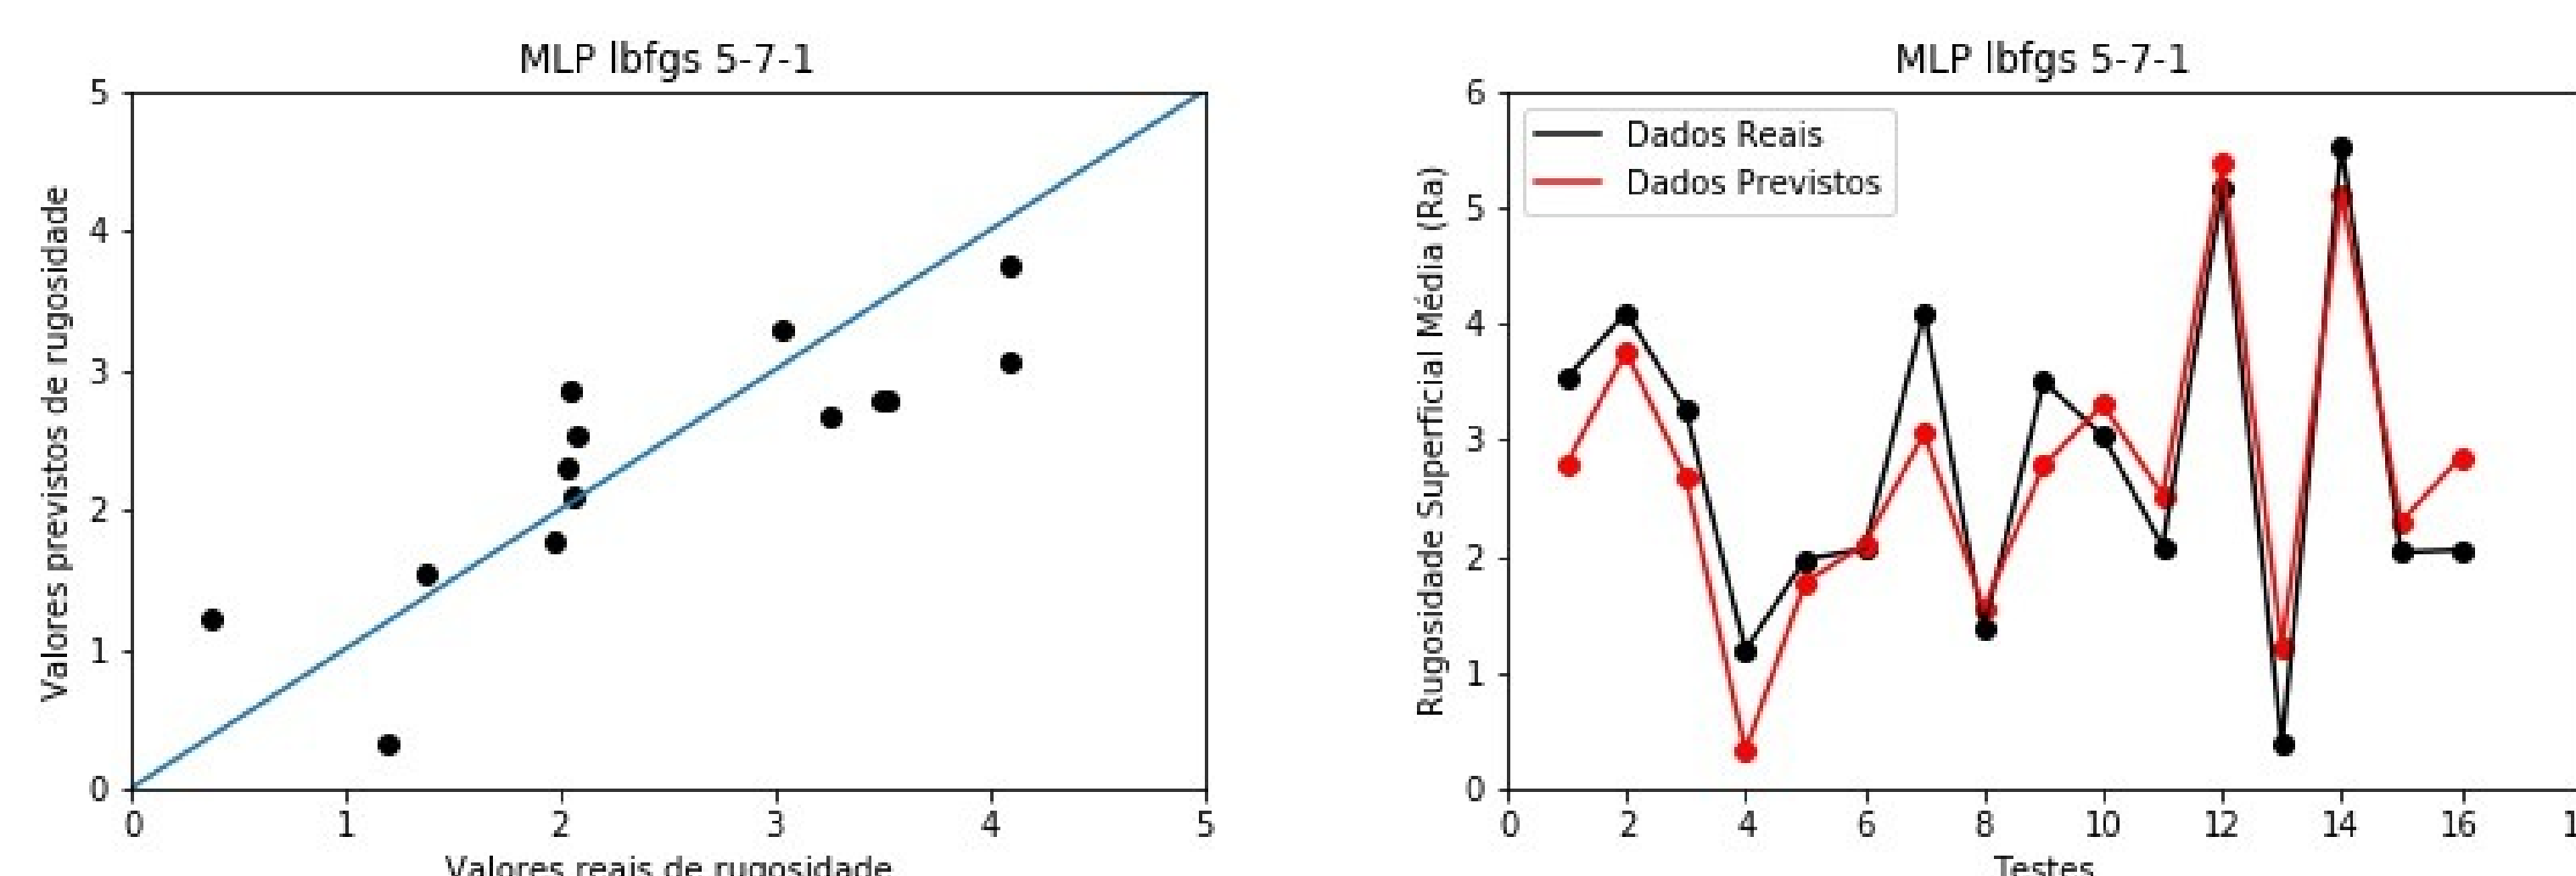


FIGURA 4: Valores reais e previstos utilizando o modelo de rede neural MLP lbfgs 5-7-1 obtido por este trabalho.

CONCLUSÕES

Utilizando novas técnicas de inteligência artificial, foi possível a obtenção de resultados iguais ou superiores aos obtidos por HOSSAIN (2012), o que justifica a continuação deste trabalho com a utilização de novos métodos e aprimorando a base de dados do modelo.

REFERÊNCIAS

HOSSAIN, S. J. Artificial Intelligence Based Surface Roughness Prediction Modeling for Three Dimensional End Milling. International Journal of Advanced Science and Technology, Vol 45, 2012.

WANG, J. et al. Residual Stresses Analysis in Ball end Milling of Nickel-Based Superalloy Inconel 718. Materials Research, 2017.

Apoio



IX Encontro de Iniciação Científica

XII Simpósio de Iniciação Científica da UFABC

14º Congresso de Iniciação Científica da USCS